

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA – ĐHQG-HCM
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

LUẬN VĂN THẠC SĨ (BẢN NHÁP)

**Bảo vệ tính riêng tư
cho người dùng dịch vụ
dựa trên vị trí**

GVHD: TS. Phan Trọng Nhân

CSE, HCMUT

Học viên: Ngô Minh Hạnh

2470010

Mục lục

Danh mục từ viết tắt	v
1 Giới thiệu đề tài	1
2 Cơ sở lý thuyết	3
2.1 Tính riêng tư vi phân (Differential Privacy)	3
2.2 Bất khả phân biệt vị trí địa lý (Geo-Indistinguishability)	3
2.3 Cơ chế lũy thừa (Exponential Mechanism)	4
2.4 Mô hình đe dọa	4
3 Nghiên cứu liên quan	5
3.1 Tổng quan các kỹ thuật bảo vệ quỹ đạo	5
3.2 Geo-I và các mở rộng	5
3.3 Tương quan thời gian	6
3.4 Học sâu và tấn công tái tạo	6
3.5 Dataset và độ đo chuẩn	6
4 Phương pháp đề xuất	7
4.1 Mô hình hệ thống và yêu cầu thiết kế	7
4.2 Phân tích baseline Thực tập 2	8
4.3 REM: Cơ chế lũy thừa trên lưới đường	9
4.4 T-REM: Bổ sung ràng buộc thời gian với trọng số công khai	10
4.5 SM-REM: Memoization chống tấn công averaging tại stay-point	11
4.6 PR-SM-REM: reuse riêng tư và đảm bảo w-event	12
4.7 Thuật toán và độ phức tạp	14
5 Thực nghiệm	15
5.1 Thiết lập	15

5.2	Độ đo và tấn công	15
5.3	Kết quả	16
5.4	Tấn công averaging tại stay-point (S4)	17
5.5	Đánh giá averaging đa-home với attacker proxy dạng-REM	18
5.6	Hệ thống mô phỏng và kịch bản sử dụng	19
6	Tổng kết	21
6.1	Kết quả đạt được	21
6.2	Hạn chế hiện tại	21
6.3	Hướng phát triển	22

Danh sách hình vẽ

5.1	Hệ thống mô phỏng: quỹ đạo thật (xanh lá), chuỗi điểm công bố bởi T-REM (đỏ, nét đứt), ước lượng kẻ tấn công HMM (xanh dương), vòng tròn QoS 200m, các POI trả về từ truy vấn k-NN, bảng chỉ số toàn quỹ đạo và đồ thị sai số theo từng bước.	20
-----	---	----

Danh sách bảng

4.1	Yêu cầu thiết kế R1–R7 (phần cơ chế giải quyết) và harm đối ứng (S1–S6, xem Chương 3).	8
5.1	Kết quả trên 20 quỹ đạo GeoLife (858 điểm), QoS 200m, seed gốc 42 dẫn xuất <i>độc lập thứ tự chạy</i> theo (seed, ε , cơ chế) (R2-009). Bayes/HMM err = sai số của adversary REM-emission proxy (m), cao hơn là riêng tư hơn — <i>cận trên</i> cho cơ chế non-REM, không phải optimal attacker; cov = HMM candidate coverage. In đậm: cơ chế đề xuất. Provenance (git commit, graph SHA-256) trong outputs/benchmark_results.json.	16
5.2	Sai số suy luận (m) của attacker MLE dạng-REM theo số báo cáo n (median trên $40 \text{ điểm} \times 8 \text{ seed}$, $\varepsilon = 0,02$, jitter $\sigma = 10\text{m}$). Thấp = attacker thắng. Cột cuối: xác suất khôi phục vị trí trong 50m ở $n=100$	18

Danh mục từ viết tắt

LBS	Location-based Services (dịch vụ dựa trên vị trí)
DP	Differential Privacy (tính riêng tư vi phân)
Geo-I	Geo-Indistinguishability (bất khả phân biệt vị trí địa lý)
GG-I	Geo-Graph-Indistinguishability
EM	Exponential Mechanism (cơ chế lũy thừa)
REM	Road-network Exponential Mechanism (đề xuất)
T-REM	Temporal Road-network Exponential Mechanism (đề xuất)
QoS	Quality of Service (chất lượng dịch vụ)
HMM	Hidden Markov Model
OSM	OpenStreetMap
PLS	Protection Location Set

Chương 1

Giới thiệu đề tài

Các dịch vụ dựa trên vị trí (LBS) đã trở thành một phần không thể thiếu trong đời sống số: điều hướng, tìm kiếm địa điểm, gọi xe, giao đồ ăn, quảng cáo cá nhân hóa và các ứng dụng y tế. Sự tiện lợi này đến từ việc người dùng liên tục báo cáo vị trí của mình cho nhà cung cấp dịch vụ. Tuy nhiên, dữ liệu quỹ đạo — chuỗi vị trí theo thời gian — có thể tiết lộ những thông tin nhạy cảm bậc nhất về một cá nhân: nơi ở, nơi làm việc, thói quen sinh hoạt, tình trạng sức khỏe, quan hệ xã hội và niềm tin tôn giáo. Khi dữ liệu này bị lạm dụng, hậu quả trải từ theo dõi, phân biệt đối xử cho tới đe dọa an toàn cá nhân.

Trong giai đoạn Thực tập 2, chúng tôi đã xây dựng một pipeline bảo vệ quỹ đạo dựa trên Geo-Indistinguishability (Geo-I) [1]: thêm nhiễu Laplace phẳng vào từng điểm, giới hạn bán kính nhiễu trong ngưỡng QoS, loại bỏ các điểm rơi vào tòa nhà/mặt nước, và làm khớp điểm giả vào lưới đường. Khảo sát văn liệu sâu hơn (Chương 3) cho thấy pipeline này tồn tại hai lỗi hình thức nghiêm trọng: (i) việc chặn bán kính nhiễu quanh vị trí thật làm hai vị trí đủ xa nhau có support đầu ra rời nhau, khiến đảm bảo Geo-I thuần không còn đúng; (ii) việc lấy mẫu lại khi điểm giả rơi vào vùng cấm điều kiện hóa phân phối đầu ra trên vị trí thật, đồng thời chính loại “lọc theo tính hợp lý” này là bề mặt mà các tấn công tái tạo hiện đại như RAOPT [2] khai thác.

Luận văn này kế thừa mục tiêu của Thực tập 2 nhưng thay thế cơ chế lỗi bằng bốn cơ chế mới hoạt động *ngay trên lưới đường*:

- **REM** (Road-network Exponential Mechanism): cơ chế lũy thừa trên tập đỉnh của đồ thị đường OSM, thỏa ϵ -Geo-I Euclid hình thức, và mọi vị trí công bố đều nằm trên đường *theo cấu trúc* — loại bỏ *tín hiệu* off-road mà tấn công map-matching/RAOPT khai thác (mức kháng tấn công cần kiểm chứng trực tiếp).
- **T-REM**: REM bổ sung trọng số khả đạt (reachability) chỉ phụ thuộc vào *điểm đã công bố trước đó* — thông tin công khai — nên đảm bảo riêng tư per-release không đổi, trong khi *giảm* tín hiệu speed-implausibility mà tấn công liên kết vận tốc dựa vào (một soft regularizer, không phải hard reachable-set).

- **SM-REM:** T-REM bổ sung memoization theo lưới công khai — cùng một chỗ luôn trả về cùng một điểm công bố — chống tấn công averaging tại stay-point (khôi phục địa chỉ nhà) trong phạm vi một cache-lifetime, rủi ro thực tế nghiêm trọng mà các cơ chế nhiễu độc lập bỏ ngỏ.
- **PR-SM-REM:** thay quyết định memoize chính xác (vốn rò pattern revisit) bằng *phép thử reuse có nhiễu* (kiểu predictive mechanism), cho chặn per-release ($\varepsilon_{\text{test}} + \varepsilon_{\text{release}}$)-Geo-I hữu hạn — đóng lỗ hổng tỷ-số-vô-hạn của memo chính xác, đổi một phần sức chống-averaging lấy một chặn hợp lệ. (Chặn w-event scalar đầy đủ cần một budget manager theo cửa sổ — chưa cài, là hướng phát triển.)

Lưu ý xuyên suốt: các đảm bảo ε -Geo-I được chứng minh cho *ideal real-arithmetic kernel*; hiện thực dấu-phẩy-động là một xấp xỉ số học (có artefact hữu-hạn-độ-chính-xác, xem Mục 4.6 và Chương 6).

Đồng thời, đối chiếu với hệ thống thực tế dẫn tới việc *phát biểu lại bài toán*: LBS không cần vị trí chính xác mà cần mức granularity tối thiểu theo mục đích; ràng buộc chất lượng vì thế được phát biểu dưới dạng (α, δ) -hữu dụng ($\Pr[d(x, z) \leq \alpha] \geq \delta$, khớp semantics trường accuracy mà mọi ứng dụng đang tiêu thụ) thay vì một ngưỡng cứng δ quanh điểm thật (vốn phá vỡ đảm bảo, Mệnh đề 4.1); và giải thuật được đánh giá theo threat model rút từ các tấn công đã xảy ra thật.

Đóng góp của luận văn tính đến bản cập nhật này:

1. Phát biểu lại bài toán theo mô hình triển khai thực tế (local, on-device, granularity theo mục đích, bảo vệ endpoint) với bảng yêu cầu thiết kế ánh xạ vào các harm thực tế (Mục 4.1);
2. Phân tích hình thức các lỗi của pipeline Thực tập 2 (Mục 4.2);
3. Bốn cơ chế REM, T-REM, SM-REM và PR-SM-REM kèm chứng minh đảm bảo riêng tư (Mục 4.3, 4.4, 4.5, 4.6);
4. Bộ khung đánh giá theo chuẩn văn liệu: tấn công suy luận Bayes tối ưu, tấn công theo đôi HMM, và tấn công averaging tại stay-point, cùng các độ đo tiện ích và tính thực tế (Chương 5);
5. Thực nghiệm trên dữ liệu GPS thật (GeoLife, Bắc Kinh) trên đồ thị đường OSM thật, so sánh với Laplace phẳng và baseline Thực tập 2;
6. Hệ thống mô phỏng trực quan ba góc nhìn (người dùng / máy chủ LBS / kẻ tấn công) minh họa các kịch bản sử dụng đời thực.

Phần còn lại của luận văn được tổ chức như sau. Chương 2 trình bày cơ sở lý thuyết. Chương 3 khảo sát các công trình liên quan và xác định khoảng trống nghiên cứu. Chương 4 mô tả và chứng minh các cơ chế đề xuất. Chương 5 trình bày thực nghiệm. Chương 6 tổng kết và nêu hướng phát triển.

Chương 2

Cơ sở lý thuyết

2.1 Tính riêng tư vi phân (Differential Privacy)

Tính riêng tư vi phân (DP) [3] là tiêu chuẩn de-facto cho riêng tư trong phân tích dữ liệu.

Định nghĩa 2.1 (ϵ -DP). Cơ chế ngẫu nhiên M thỏa ϵ -differential privacy nếu với mọi cặp tập dữ liệu D_1, D_2 khác nhau đúng một bản ghi và mọi tập kết quả $S \subseteq \text{Range}(M)$:

$$\Pr[M(D_1) \in S] \leq e^\epsilon \Pr[M(D_2) \in S].$$

Hai tính chất được dùng xuyên suốt luận văn: *kết hợp tuần tự* (áp dụng k cơ chế ϵ_i -DP lên cùng dữ liệu cho $(\sum_i \epsilon_i)$ -DP, kể cả khi cơ chế sau được chọn thích nghi theo đầu ra của cơ chế trước) và *bất biến hậu xử lý* (mọi phép biến đổi trên đầu ra *không truy cập dữ liệu gốc* bảo toàn mức riêng tư).

2.2 Bất khả phân biệt vị trí địa lý (Geo-Indistinguishability)

Geo-I [1] tổng quát hóa DP sang không gian metric.

Định nghĩa 2.2 (ϵ -Geo-I). Cơ chế M thỏa ϵ -Geo-Indistinguishability nếu với mọi vị trí thật $x, x' \in \mathcal{X}$ và mọi tập đầu ra S :

$$\Pr[M(x) \in S] \leq e^{\epsilon d(x, x')} \Pr[M(x') \in S],$$

với d là khoảng cách Euclid. Tham số ϵ có đơn vị nghịch đảo khoảng cách (mỗi mét): trong bán kính r bất kỳ, mức phân biệt tối đa là ϵr .

Cơ chế Laplace phẳng. Cơ chế kinh điển đạt ϵ -Geo-I là cộng nhiễu lấy từ phân phối Laplace phẳng (polar Laplace): góc $\theta \sim \text{Uniform}[0, 2\pi)$ và bán kính r có mật độ $p(r) = \epsilon^2 r e^{-\epsilon r}$, tức

$r \sim \text{Gamma}(2, 1/\varepsilon)$ với kỳ vọng $\mathbb{E}[r] = 2/\varepsilon$.

Nhận xét 2.1. Lấy $r \sim \text{Exponential}(1/\varepsilon)$ (như hiện thực Thực tập 2) *không* tạo ra phân phối Laplace phẳng: mật độ hai chiều tương ứng tỷ lệ với $e^{-\varepsilon r}/r$, phân kỳ khi $r \rightarrow 0$, và tỷ số mật độ giữa hai vị trí thật không bị chặn — cơ chế thu được không thỏa Định nghĩa 2.2.

2.3 Cơ chế lũy thừa (Exponential Mechanism)

Với miền đầu ra rời rạc V và hàm chất lượng $q(x, v)$, cơ chế lũy thừa [4] chọn v với xác suất tỷ lệ $\exp(\varepsilon q(x, v)/(2\Delta q))$. Trong không gian metric, chọn $q(x, v) = -d(x, v)$ cho một cơ chế thỏa ε -Geo-I trên V (chứng minh chi tiết ở Định lý 4.1); hệ số $1/2$ hấp thụ sự thay đổi của hằng số chuẩn hóa giữa hai vị trí thật. Đây là nền tảng của cơ chế đề xuất trong Chương 4.

2.4 Mô hình đe dọa

Chúng tôi xét kẻ tấn công theo nguyên lý Kerckhoffs: biết *cơ chế* và tham số của nó, giữ một *prior* trên các vị trí khả dĩ, và quan sát toàn bộ chuỗi điểm công bố $z_1, \dots, z_T$. Hai hiện thân được dùng để đánh giá (Chương 5): tấn công suy luận Bayes tối ưu trên từng điểm, và tấn công theo dõi HMM khai thác tương quan thời gian giữa các điểm liên tiếp — chuẩn đánh giá được xác lập bởi [5, 6].

Chương 3

Nghiên cứu liên quan

3.1 Tổng quan các kỹ thuật bảo vệ quỹ đạo

Chow và Mokbel [7] hệ thống hóa các kỹ thuật bảo vệ quỹ đạo trong LBS liên tục và xuất bản dữ liệu: spatial cloaking, mix-zones, path confusion và dummy. Hạn chế chung của nhóm kỹ thuật này là không có đảm bảo hình thức và dễ vỡ trước tấn công dựa trên tri thức nền. Hai công trình của nhóm nghiên cứu HCMUT — PP^{ST} -tree [8] và KUR-Algorithm [9] — bảo vệ quỹ đạo ở tầng cơ sở dữ liệu bằng k-anonymity trên các vùng dự đoán chuyển động, đặt nền cho hướng tiếp cận nhận biết ngữ cảnh đường bộ mà luận văn kế thừa.

3.2 Geo-I và các mở rộng

Geo-I [1] cung cấp đảm bảo định lượng per-point nhưng có ba hạn chế đã được chỉ rõ trong văn liệu: không gian được đối xử đồng nhất (khắc phục bởi elastic metrics [10]); metric Euclid không khớp ngữ cảnh đường bộ; và đầu ra có thể rơi vào vị trí phi thực tế. Bordenabe và cộng sự [11] xây dựng cơ chế Geo-I tối ưu tiện ích bằng quy hoạch tuyến tính. Oya và cộng sự [12] chỉ ra Geo-I đơn lẻ có thể để lọt rủi ro suy luận Bayes cao, khuyến nghị bổ sung độ đo sai số suy luận kỳ vọng.

Geo-I trên lưới đường. Gần với luận văn nhất, Takagi và cộng sự [13] đề xuất *Geo-Graph-Indistinguishability* (GG-I): miền đầu ra là tập đỉnh đồ thị đường, metric là khoảng cách đường đi ngắn nhất d_s , và cơ chế Graph-Exponential Mechanism $\Pr[o \mid v] \propto \exp(-\frac{\epsilon}{2}d_s(v, o))$. Họ chứng minh mọi cơ chế ϵ -Geo-I hậu xử lý bằng phép chiếu về đỉnh gần nhất cũng thỏa ϵ -GG-I, và GEM trội hơn Laplace-rời-snap trên trade-off riêng tư–tiện ích. Cơ chế REM của luận văn (Mục 4.3) là phiên bản dùng metric Euclid của hướng này, đổi độ chính xác metric lấy chi phí tính toán $O(|V|)$ thay vì Dijkstra trên toàn đồ thị.

3.3 Tương quan thời gian

Xiao và Xiong [6] chỉ ra Geo-I per-point suy giảm dưới tương quan thời gian: kẻ tấn công lan truyền prior qua ma trận chuyển Markov và lọc nhiễu như một bộ lọc Bayes. Họ đề xuất δ -location set và cơ chế PIM. PIVE [14] kết hợp DP với ràng buộc sai số suy luận qua Protection Location Set hai pha; tuy nhiên Zhang và cộng sự [15] đã chứng minh cấu trúc PLS thích nghi của PIVE không đạt được các đảm bảo như tuyên bố. PTPPM [16] thay cơ chế lũy thừa bằng Permute-and-Flip trên PLS. Bản preprint gần nhất của nhóm này [17] (11/2025, chưa qua bình duyệt) kết hợp lưới đường với tương quan thời gian — xác nhận đây là khoảng trống nghiên cứu đang mở mà luận văn nhắm tới, với cách tiếp cận đơn giản hơn và đảm bảo sạch hơn (trọng số công khai, Định lý 4.2).

3.4 Học sâu và tấn công tái tạo

Các mô hình sinh quỹ đạo (LSTM-TrajGAN [18], DiffTraj [19], Diff-RNTraj trên lưới đường) cho quỹ đạo giả trông thực nhưng không có đảm bảo DP; huấn luyện kèm DP-SGD làm tiện ích suy giảm mạnh [20]. Quan trọng với luận văn là tấn công RAoPT [2]: mạng LSTM học “chữ ký” của nhiễu DP (điểm rơi ngoài đường, trên mặt nước) và tái tạo quỹ đạo gốc, giảm hơn 65% khoảng cách Euclid/Hausdorff về quỹ đạo thật trên T-Drive với $\epsilon \leq 1$. Đây là luận cứ thực nghiệm trung tâm cho thiết kế “đầu ra trên đường theo cấu trúc” của REM.

3.5 Dataset và độ đo chuẩn

Khảo sát các công trình 2013–2026 cho thấy nhánh trajectory-level dùng áp đảo **GeoLife** [21] (182 người dùng, 17.621 quỹ đạo GPS, Bắc Kinh, 91% mật độ 1–5 giây) — đây cũng là dataset của PIVE, PIM, RAoPT. Bộ độ đo chuẩn mà hội đồng/bình duyệt kỳ vọng gồm: (*privacy*) sai số suy luận kỳ vọng dưới tấn công Bayes tối ưu [5] và tấn công theo dõi Markov/HMM [6]; (*utility*) quality loss kỳ vọng và độ chính xác truy vấn k-NN POI; (*realism*) tỷ lệ điểm trên đường và tính hợp lý tốc độ giữa hai điểm công bố liên tiếp. Chương 5 hiện thực đầy đủ bộ độ đo này.

Chương 4

Phương pháp đề xuất

4.1 Mô hình hệ thống và yêu cầu thiết kế

Reframe bài toán. Đối chiếu với hệ thống LBS thực tế (Chương 3) cho thấy dịch vụ không cần vị trí *chính xác* mà cần *mức granularity tối thiểu đủ cho một mục đích*. Apple và Android đều phơi bày các tầng độ chính xác theo query, xử lý “significant location” on-device và làm mờ điểm đầu/cuối hành trình; quy định (GDPR Điều 5; ngưỡng “precise geolocation” 1.750–1.850 ft của luật bang Mỹ; các lệnh FTC với Kochava/X-Mode/InMarket) áp đặt purpose limitation, data minimization và loại trừ vị trí nhạy cảm. Tuy nhiên thứ được triển khai thực tế chỉ là *lượng tử hóa heuristic không đảm bảo* (snap-to-grid, làm tròn) hoặc *DP hình thức chỉ ở phía máy chủ trên dữ liệu tổng hợp*. Luận văn vì thế phát biểu lại bài toán: từ “làm nhiều mỗi điểm trong bán kính QoS δ toàn cục” thành **phát ra mức tối thiểu theo mục đích, on-device, trên lưới đường, với đảm bảo nhận thức endpoint và tương quan, đánh giá theo threat model rút từ các tấn công thật**.

Mô hình hệ thống. Kiến trúc *đích* đặt cơ chế *client-side* (mô hình local), tại tầng vị trí của thiết bị — tiền lệ đã triển khai cho hàng tỷ máy là Android LocationFudger và iOS approximate location, cùng Location Guard/LP-Doctor cho planar Laplace. Đây là nơi đặt duy nhất mà đảm bảo giữ được với *mọi* bên downstream (máy chủ LBS, ad exchange, data broker, trát tòa). *Lưu ý phạm vi*: artifact trong luận văn là một *reference mechanism* + simulator Flask phía server, chưa phải một hiện thực mobile on-device; các vấn đề tích hợp OS, secure cache, TTL/rotation định danh là ngoài phạm vi (Chương 6). Cơ chế được biết: (a) vị trí thật hiện tại; (b) *đồ thị đường công khai lưu trên thiết bị* (~5,9MB cho bbox thí nghiệm, nhỏ hơn nhiều so với bản đồ offline 200–950MB mà điện thoại vẫn chứa — điều kiện hóa trên nó không tổn privacy, là post-processing); (c) *các điểm đã CÔNG BỐ trước đó của chính nó* (không phải vị trí thật quá khứ). Adversary thấy: điểm công bố on-road cộng metadata tầng truyền (timestamp, nội dung query, định danh có thể liên kết) — mô hình hóa là LBS honest-but-curious hoặc broker giữ toàn bộ chuỗi công bố dưới một định danh.

Yêu cầu thiết kế và phạm vi trung thực. Bảng 4.1 liệt kê các yêu cầu rút từ industry/pháp lý và harm chúng đối ứng. Cơ chế đề xuất (REM/T-REM/SM-REM) làm được R1,R3,R4,R5,R6 và một phần R2,R7; *không* tự làm được R8 (xoay định danh — cần policy phía định danh) và R9–R12 (consent, giới hạn mục đích/lưu trữ, minh bạch — thuộc governance phía máy chủ hoặc tầng UX). Đây là ranh giới đóng góp cần nêu thẳng: một cơ chế nhiều tọa độ không thể thay thế kiểm soát định danh và quản trị dữ liệu.

Bảng 4.1: Yêu cầu thiết kế R1–R7 (phần cơ chế giải quyết) và harm đối ứng (S1–S6, xem Chương 3).

#	Yêu cầu	Nguồn	Harm
R1	Perturbation client-side/on-device	Apple; AOSP; GDPR	tiền đề
R2	Granularity theo mục đích (chọn từ context công khai)	GDPR 5(1)(c); Micinski’13	S1,S6
R3	Bất khả phân biệt hình thức vị trí gần	W3C; Geo-I	S1,S5
R4	Output on-road hợp lệ	LocationFudger; REM	S2
R5	Kháng tương quan/velocity (điều kiện trên điểm đã công bố)	Xiao–Xiong; T-REM	S3
R6	Ổn định khi báo lặp (anti-averaging)	W3C; RAPPOR; LP-Doctor	S4
R7	Bảo vệ endpoint/stay-point hạng nhất	Apple; Strava; Dhondt’22	S4,S6

4.2 Phân tích baseline Thực tập 2

Pipeline Thực tập 2 gồm bốn bước cho mỗi điểm thật x_t : (i) cộng nhiễu Laplace phẳng với bán kính bị chặn tại ngưỡng QoS δ ; (ii) nếu điểm giả rơi vào tòa nhà/mặt nước thì lấy mẫu lại (tối đa N lần); (iii) làm mượt liên tục theo hai điểm giả trước, có kiểm tra lại QoS so với điểm thật; (iv) làm khớp về đỉnh đường gần nhất nếu vẫn thỏa QoS. Hai mệnh đề sau chỉ ra các bước (i)–(iii) phá vỡ đảm bảo hình thức. (Trong benchmark Chương 5, baseline được dùng là một *surrogate đơn giản hoá* — bỏ bước tìm đường thay thế và bước reject theo tòa nhà/mặt nước — nên nhãn “Baseline TT2 (surrogate)”; so sánh đối chứng với pipeline đầy đủ là hướng phát triển.)

Mệnh đề 4.1 (Chặn bán kính quanh điểm thật phá vỡ Geo-I). *Gọi M_δ là cơ chế cộng nhiễu với bán kính $r' = \min(r, \delta)$ quanh vị trí thật x . Khi đó M_δ không thỏa ε -Geo-I với bất kỳ ε hữu hạn nào trên miền $\mathcal{X}$ có đường kính lớn hơn 2δ .*

Chứng minh. Support của $M_\delta(x)$ là hình tròn đóng $\bar{B}(x, \delta)$. Chọn x, x' với $d(x, x') > 2\delta$ thì $\bar{B}(x, \delta) \cap \bar{B}(x', \delta) = \emptyset$. Với $S = \bar{B}(x, \delta)$ ta có $\Pr[M_\delta(x) \in S] = 1$ trong khi $\Pr[M_\delta(x') \in S] = 0$; không tồn tại hằng số hữu hạn $e^{\varepsilon d(x, x')}$ chặn được tỷ số này. $\square$

Cần tách ba trường hợp khác nhau (theo phản biện V-010/R2-011); chỉ trường hợp (b) mới là lỗi của baseline:

Mệnh đề 4.2 (Điều kiện hóa trên tập cho phép công khai cố định — giữ 2ε). *Cho tập cho phép cố định, công khai A (độc lập với input) với $K(A | x) > 0$ mọi x . Cơ chế điều kiện*

$K_A(z \mid x) = K(z \mid x) / K(A \mid x)$ thỏa

$$\frac{K_A(z \mid x)}{K_A(z \mid x')} = \frac{K(z \mid x)}{K(z \mid x')} \cdot \frac{K(A \mid x')}{K(A \mid x)} \leq e^{\varepsilon d(x, x')} \cdot e^{\varepsilon d(x, x')} = e^{2\varepsilon d(x, x')}.$$

Mệnh đề 4.3 (Lấy mẫu lại theo vùng cấm phụ thuộc input phá vỡ Geo-I). *Nếu tập cho phép A_x phụ thuộc input (ví dụ “không rơi vào tòa nhà/mặt nước quanh x ”), tỷ số có thể vô hạn. Phản ví dụ tối thiểu: base kernel K đều trên $\{0, 1\}$ với mọi input (0-DP); đặt $A_a = \{0\}$, $A_b = \{1\}$. Sau điều kiện, $K_A(0 \mid a) = 1$ nhưng $K_A(0 \mid b) = 0$ — likelihood ratio vô hạn. Pipeline Thực tập 2 dùng đúng dạng A_x này (vùng cấm + kiểm QoS quanh x).*

(Trường hợp (c) — retry hữu hạn rồi fallback — tạo một phân phối khác với conditioning vô hạn và phải phân tích riêng; không dùng trong các cơ chế đề xuất.) Cùng với Nhận xét 2.1 (bán kính nhiều lấy sai phân phối), các phân tích cho thấy ε danh nghĩa của baseline không phải một đảm bảo hợp lệ; mọi so sánh “cùng ε ” vì vậy chỉ mang tính tham khảo. Ngược lại, phép chiếu đầu ra về đỉnh đường gần nhất ở bước (iv) — nếu bỏ điều kiện kiểm tra QoS so với điểm thật — là hậu xử lý độc lập dữ liệu và bảo toàn mức riêng tư; quan sát này dẫn tới thiết kế dưới đây.

4.3 REM: Cơ chế lũy thừa trên lưới đường

Cho đồ thị đường $G = (V, E)$ trích từ OSM cho vùng quan tâm; tập đỉnh V là công khai. REM chọn trực tiếp một đỉnh làm vị trí công bố:

Định nghĩa 4.1 (REM). Với vị trí thật x và ngân sách ε :

$$\Pr[\text{REM}(x) = v] = \frac{\exp(-\frac{\varepsilon}{2} d(x, v))}{\sum_{u \in V} \exp(-\frac{\varepsilon}{2} d(x, u))}, \quad v \in V.$$

Định lý 4.1 (REM thỏa ε -Geo-I). *Với mọi $x, x' \in \mathbb{R}^2$ và mọi $v \in V$: $\Pr[\text{REM}(x) = v] \leq e^{\varepsilon d(x, x')} \Pr[\text{REM}(x') = v]$.*

Chứng minh. Đặt $Z(x) = \sum_{u \in V} e^{-\frac{\varepsilon}{2} d(x, u)}$. Xét tỷ số

$$\frac{\Pr[\text{REM}(x) = v]}{\Pr[\text{REM}(x') = v]} = \underbrace{\frac{e^{-\frac{\varepsilon}{2} d(x, v)}}{e^{-\frac{\varepsilon}{2} d(x', v)}}}_{(A)} \cdot \underbrace{\frac{Z(x')}{Z(x)}}_{(B)}.$$

Với (A): theo bất đẳng thức tam giác $d(x', v) - d(x, v) \leq d(x, x')$, nên $(A) = e^{\frac{\varepsilon}{2}(d(x', v) - d(x, v))} \leq e^{\frac{\varepsilon}{2} d(x, x')}$. Với (B): với mỗi $u \in V$, $d(x', u) \geq d(x, u) - d(x, x')$, do đó $e^{-\frac{\varepsilon}{2} d(x', u)} \leq e^{\frac{\varepsilon}{2} d(x, x')} e^{-\frac{\varepsilon}{2} d(x, u)}$.

Lấy tổng theo u : $Z(x') \leq e^{\frac{\varepsilon}{2} d(x, x')} Z(x)$, tức $(B) \leq e^{\frac{\varepsilon}{2} d(x, x')}$. Nhân hai chặn được $e^{\varepsilon d(x, x')}$. $\square$

Nhận xét 4.1 (Quan hệ với GEM và điều kiện metric của guarantee). REM chính là bản dùng khoảng cách *Euclid* của Graph-Exponential Mechanism (GEM) trong [13]: GEM chấm điểm

bằng khoảng cách đường đi ngắn nhất d_s và chỉ thỏa ε -GG-I (không có đảm bảo theo Euclid), trong khi REM chấm điểm bằng d_{Euclid} nên Định lý 4.1 cho ε -Geo-I *Euclid* thật sự. Điểm mấu chốt: guarantee bám vào metric dùng trong số mũ — dùng Euclid thì phát biểu Euclid, dùng graph thì chỉ được phát biểu GG-I. Việc miền đầu ra rời rạc/on-road không phá lập luận exponential mechanism.

Nhận xét 4.2 (Tính thực tế theo cấu trúc). Mọi đầu ra của REM là một đỉnh đường: các tấn công lọc theo tính hợp lý không gian (map-matching, phát hiện điểm trên mặt nước — cơ sở của RAOPT [2]) không còn thông tin để khai thác.

Nhận xét 4.3 (Tập ứng viên cố định — không dùng cutoff). Hiện thực lấy tổng chuẩn hóa trên toàn bộ tập đỉnh V của đồ thị (cố định, công khai), không dùng bất kỳ cutoff nào quanh điểm thật. Đây là điều kiện để Định lý 4.1 đúng: nếu cắt support về $V \cap B(x, R)$ (phụ thuộc điểm thật x), hai điểm ε -sát nhau nhưng ở hai phía biên cutoff của một đỉnh v cho $P[M(x)=v] > 0$ trong khi $P[M(x')=v] = 0$ — likelihood ratio vô hạn, phá vỡ pure Geo-I (khối lượng đuôi nhỏ không cứu được). Chi phí full-support cho đồ thị Bắc Kinh ($|V| \approx 78k$ đỉnh) là một 2-norm vector hóa cộng một lần lấy mẫu categorical mỗi release, dưới mili-giây — trong ngân sách thời gian thực của LBS.

4.4 T-REM: Bổ sung ràng buộc thời gian với trọng số công khai

Nhược điểm của REM (và mọi cơ chế nhiễu độc lập theo thời gian) là hai điểm công bố liên tiếp có thể cách nhau phi thực tế, tạo tín hiệu cho tấn công liên kết vận tốc. T-REM khắc phục bằng trọng số khả đạt tính từ điểm *đã công bố* z_{t-1} và khoảng thời gian Δt (đều công khai):

$$w_t(v) = \exp\left(-\lambda \cdot \max(0, d(z_{t-1}, v) - v_{\max}\Delta t - s)\right),$$

với $v_{\max}$ là tốc độ tối đa hợp lý, s là biên nói lỏng, λ là hệ số phạt. Cơ chế trở thành

$$\Pr[\text{TREM}(x_t) = v \mid z_{t-1}] = \frac{w_t(v) e^{-\frac{\varepsilon}{2}d(x_t, v)}}{\sum_{u \in V} w_t(u) e^{-\frac{\varepsilon}{2}d(x_t, u)}}.$$

Định lý 4.2 (Trọng số công khai bảo toàn đảm bảo). *Với mọi hàm trọng số $w : V \rightarrow (0, 1]$ không phụ thuộc vị trí thật x_t (chỉ phụ thuộc $z_{<t}$, Δt và các hằng số công khai), cơ chế T-REM thỏa ε -Geo-I tại mỗi bước: với mọi x, x' và $v \in V$,*

$$\Pr[\text{TREM}(x) = v \mid z_{t-1}] \leq e^{\varepsilon d(x, x')} \Pr[\text{TREM}(x') = v \mid z_{t-1}].$$

Chứng minh. Lặp lại chứng minh Định lý 4.1 với $Z_w(x) = \sum_u w(u) e^{-\frac{\varepsilon}{2}d(x, u)}$. Thừa số (A) không đổi vì $w(v)$ xuất hiện ở cả tử và mẫu nên triệt tiêu: $(A) = e^{\frac{\varepsilon}{2}(d(x', v) - d(x, v))} \leq e^{\frac{\varepsilon}{2}d(x, x')}$.

Với (B): từng số hạng thỏa $w(u)e^{-\frac{\varepsilon}{2}d(x',u)} \leq e^{\frac{\varepsilon}{2}d(x,x')}w(u)e^{-\frac{\varepsilon}{2}d(x,u)}$ (trọng số $w(u) > 0$ giữ nguyên hai vế), nên $Z_w(x') \leq e^{\frac{\varepsilon}{2}d(x,x')}Z_w(x)$. Kết luận như Định lý 4.1. Điều kiện then chốt là w đo được theo thông tin công khai: nếu w phụ thuộc x_t , thừa số (A) không triệt tiêu và lập luận sụp đổ — đây chính là lỗi của bước làm mượt có kiểm tra QoS trong baseline (Mệnh đề 4.1). $\square$

Nhận xét 4.4 (Ngân sách toàn quỹ đạo). Chuỗi T lần công bố nhiều độc lập tiêu tốn $\varepsilon_{\text{traj}} = T\varepsilon$ theo kết hợp tuần tự thích nghi (trọng số w_t chọn theo đầu ra trước đó là hợp lệ trong khuôn khổ adaptive composition). Đây là trần worst-case trung thực. SM-REM (Mục 4.5) *không* siết được trần này về mức toàn-quỹ-đạo: nó chỉ đạt đảm bảo cho *vị trí tĩnh lặp lại* (Định lý 4.3), còn pattern revisit thì rõ ràng (Nhận xét 4.5).

4.5 SM-REM: Memoization chống tấn công averaging tại stay-point

Mọi cơ chế nhiều độc lập theo thời gian — kể cả REM/T-REM — đều rõ ràng dưới *báo cáo lặp từ một vị trí tĩnh*: kẻ tấn công thấy n release độc lập $z_1, \dots, z_n$ của cùng một điểm thật x (ví dụ ở nhà qua đêm) và lấy trung bình; ước lượng hội tụ về x với sai số $O(1/\sqrt{n})$. Đây là phát biểu hình thức trong [22] (“khi người dùng không di chuyển... các vị trí báo cáo tập trung quanh vị trí thật, lộ hoàn toàn nó khi số truy vấn tăng”), và là cơ chế đằng sau vụ Strava khôi phục địa chỉ nhà (84–95%, [23, 24]) cùng home fingerprinting của data broker. Đây chính là kịch bản S4 mà bản PTPPM lưới đường mới nhất [17] bỏ ngỏ: vì cơ chế của họ là *stateless* (Permute-and-Flip lấy mẫu độc lập mỗi timestamp), báo cáo lặp cùng một vị trí thật vẫn bị averaging — đây là suy luận của luận văn từ thiết kế của họ, không phải một trích dẫn thừa nhận.

Cơ chế. SM-REM phân hoạch không gian bằng một *lưới công khai cố định* kích thước g , với đại diện công khai $\text{rep}(C)$ (tâm ô) mỗi ô. Lần đầu điểm thật rơi vào ô C , một release r_C được lấy mẫu bằng luật T-REM *tại* $\text{rep}(C)$ (không tại toạ độ thật) và lưu lại; mọi báo cáo sau có điểm thật rơi vào C đều trả về *cùng* r_C . Sample tại $\text{rep}(C)$ làm phân phối release của mọi điểm trong một ô giống hệt nhau — điều kiện cho phát biểu mức-ô. Quyết định memoize chỉ dựa trên lưới công khai (memoize mọi lần), không có phép thử phụ thuộc dữ liệu.

Định lý 4.3 (Đảm bảo cho vị trí tĩnh lặp lại — phạm vi hẹp có chủ ý). *Cố định một vị trí thật x thuộc ô C và cho người dùng báo cáo x đúng T lần. Gọi $Z \sim \text{REM}(\text{rep}(C))$ là release đầu. Transcript $(Z, \dots, Z)$ là hậu xử lý xác định của một mẫu Z , nên: (i) thừa hưởng đảm bảo ε -Geo-I mức-ô của Z ; và (ii) mang đúng lượng thông tin của một release bất kể T — trung bình số học của T bản sao giống hệt không giảm phương sai, nên tấn công averaging (S4) không thu được gì.*

Chứng minh. Sau khi Z được lấy mẫu, mọi phát ra sau là tra bảng xác định trả về Z — một hàm của riêng Z — nên bất biến hậu xử lý ([13], bổ đề hậu xử lý) cho (i). Với (ii), phân phối của $(Z, \dots, Z)$ đồng nhất với phân phối của Z ; ước lượng trung bình $\frac{1}{T} \sum Z = Z$ có cùng phân bố với một mẫu đơn, độc lập với T . $\square$

Nhận xét 4.5 (Điều KHÔNG được khẳng định — và vì sao (V-003)). Ta *không* khẳng định một định lý toàn-quỹ-đạo kiểu “ $\varepsilon \cdot$ (số ô riêng biệt)-Geo-I trên quỹ đạo tùy ý”. Memoization chính xác làm pattern hit/miss của cache trở thành hàm xác định của *pattern revisit bí mật*, và pattern này rò rỉ: với hai quỹ đạo $X = (a, a)$ và $X' = (a, b)$ (b ở ô khác), biến cố $\{z_2 \neq z_1\}$ có xác suất 0 dưới X nhưng > 0 dưới X' — likelihood ratio vô hạn một chiều. Lưới công khai không làm một lần revisit bí mật trở thành công khai. Một đảm bảo bảo vệ cả pattern revisit đòi hỏi *quyết định reuse tự nó phải riêng tư vi phân* (phép thử private kiểu predictive mechanism [22]) — được đặt làm hướng phát triển (Chương 6), không phải phần đã chứng minh ở đây.

Nhận xét 4.6 (Cũng không phải Geo-I Euclid — gián đoạn ở biên). Ngay ở mức một release, quantize $x \rightarrow \text{rep}(C)$ là rời-rạc-hóa phía đầu vào: hai điểm sát nhau hai bên biên ô nhận release độc lập, tỷ số tới $\exp(\varepsilon \cdot \text{cellwidth})$. SM-REM vì thế *không* thỏa ε -Geo-I Euclid như REM/T-REM — **không thể vừa có Geo-I Euclid sạch vừa có memoization chống averaging từ cùng một tham số**; đây đúng là lý do Android LocationFudger ghép snap-to-grid với offset ngẫu nhiên bên. Mặc định $g = 60\text{m}$; release snap về đỉnh đường dùng chung nên giá trị nhất quán không tự trở thành fingerprint duy nhất.

4.6 PR-SM-REM: reuse riêng tư và đảm bảo w-event

Nhận xét 4.5 chỉ ra vì sao SM-REM *không* có đảm bảo toàn quỹ đạo: quyết định reuse (hit/miss cache) là hàm xác định của pattern revisit bí mật. Cách và nguyên lý (predictive mechanism [22]; kế toán w-event [25]) là làm chính *quyết định reuse* riêng tư vi phân.

Cơ chế. Ở mỗi bước t , dự đoán $\tilde{z}_t = \text{điểm đã công bố trước đó } z_{t-1}$ (parrot predictor — công khai, chỉ là hàm của transcript). Chạy *phép thử ngưỡng có nhiễu*:

$$d(x_t, \tilde{z}_t) + \text{Lap}(1/\varepsilon_{\text{test}}) \leq \theta \quad \Rightarrow \quad \text{REUSE } \tilde{z}_t; \quad \text{ngược lại} \Rightarrow \text{RESAMPLE bằng REM.}$$

Reuse tốn đúng $\varepsilon_{\text{test}}$; resample tốn $\varepsilon_{\text{test}} + \varepsilon$. θ là bán kính reuse công khai; trạng thái chỉ phụ thuộc thông tin công khai và các release quá khứ, không bao giờ phụ thuộc $x_{\leq t}$ thô.

Định lý 4.4 (Chặn per-step của PR-SM-REM). *Kernel một bước là hỗn hợp hai nhánh: tại $z = h$ có khối lượng $q_x(h) + (1 - q_x(h))R_x(h)$; tại $z \neq h$ có $(1 - q_x(h))R_x(z)$, với $q_x(h) = \Pr[d(x, h) + \text{Lap}(1/\varepsilon_{\text{test}}) \leq \theta]$ và R là kernel REM với ngân sách $\varepsilon_{\text{release}}$. Vì thống kê $d(x, h)$ có độ nhạy metric bằng 1 theo x và h công khai, nhánh RESAMPLE mang cả thừa số phép thử lẫn*

release REM, nên chặn per-step worst-case là

$$\frac{K_x(z \mid h)}{K_{x'}(z \mid h)} \leq \exp((\varepsilon_{\text{test}} + \varepsilon_{\text{release}}) d(x, x')),$$

tức $(\varepsilon_{\text{test}} + \varepsilon_{\text{release}})$ -**Geo-I** (bước đầu tiên, chưa có dự đoán, chỉ tốn $\varepsilon_{\text{release}}$). Do đó biến cố $\{z \neq h\}$ có tỷ số hữu hạn $\leq \exp((\varepsilon_{\text{test}} + \varepsilon_{\text{release}})d(x, x'))$ — đây mới là điều đóng lỗ hổng tỷ-số-vô-hạn của memo chính xác (Nhận xét 4.5), không phải chặn chỉ- $\varepsilon_{\text{test}}$.

Chứng minh. Điều kiện trên cùng một public history (nên h , q 's form giống nhau ở hai input). Đặt $d = d(x, x')$ và $c = e^{(\varepsilon_{\text{test}} + \varepsilon_{\text{release}})d}$. Ba chặn thành phần: $q_x \leq e^{\varepsilon_{\text{test}}d} q_{x'}$ và $1 - q_x \leq e^{\varepsilon_{\text{test}}d} (1 - q_{x'})$ (query $d(\cdot, h)$ độ nhảy $1 +$ nhiễu Laplace), và $R_x(z) \leq e^{\varepsilon_{\text{release}}d} R_{x'}(z)$ (Định lý 4.1). Nhánh $z \neq h$: $K_x(z \mid h) = (1 - q_x)R_x(z) \leq e^{\varepsilon_{\text{test}}d} e^{\varepsilon_{\text{release}}d} (1 - q_{x'})R_{x'}(z) = c K_{x'}(z \mid h)$. Nhánh $z = h$: cả hai số hạng chịu cùng hệ số c (số hạng q_x chịu $e^{\varepsilon_{\text{test}}d} \leq c$; số hạng $(1 - q_x)R_x(h)$ chịu c), nên tổng $q_x + (1 - q_x)R_x(h) \leq c [q_{x'} + (1 - q_{x'})R_{x'}(h)] = c K_{x'}(h \mid h)$ — không dùng “tỷ số của tổng” một cách không giải thích. Liệt kê hai-vertex ($a=0\text{m}$, $b=100\text{m}$, $h=a$, $\theta=200\text{m}$, $\varepsilon_{\text{test}}=\varepsilon_{\text{release}}=0,01$; $z=b$): tỷ số $= e^{1.5}$, vượt chặn cũ e^1 nhưng thỏa e^2 — được test hồi quy hóa ở `tests/test_pr_privacy_bound.py`. $\square$

Nhận xét 4.7 (Ideal kernel vs hiện thực dấu-phẩy-động). Mọi chặn ở trên là cho *ideal real-arithmetic kernel*. Sampler Gumbel-max và phép thử Laplace trong hiện thực dùng RNG 53-bit hữu hạn nên có span bị chặn: một đỉnh có logit thấp hơn leader quá $\approx 40,34$ không bao giờ được chọn, tạo zero-support phụ thuộc input (tỷ số vô hạn ở mức executable). Vì vậy luận văn không tuyên bố hiện thực float thỏa pure ε -Geo-I; nó là một xấp xỉ số học của ideal kernel. Chúng minh pure-DP hữu-hạn-độ-chính-xác (exact discrete sampler với tinh chỉnh bit không giới hạn) là hướng phát triển. Xem `tests/test_sampler_support.py` (verifier R2-006).

Nhận xét 4.8 (Từ per-step tới quỹ đạo — và điều chưa cài (R2-002)). Kết hợp tuần tự trên cửa sổ w (metric $D_\infty(X, X') = \max_t d(x_t, x'_t)$) cho worst-case $w(\varepsilon_{\text{test}} + \varepsilon_{\text{release}})$ mỗi cửa sổ (cửa sổ đầu: $\varepsilon_{\text{release}} + (w - 1)(\varepsilon_{\text{test}} + \varepsilon_{\text{release}})$). Hiện thực chưa có budget manager/privacy-filter theo cửa sổ; `n_resample` chỉ là chẩn đoán hậu nghiệm, không phải một guarantee ex-ante. Muốn tuyên bố một scalar ε_w nhỏ hơn worst-case cần thêm một allocator theo cửa sổ và lấy supremum trên mọi public transcript — đặt làm hướng phát triển (Chương 6). Để so sánh công bằng với REM ε -Geo-I, đặt $\varepsilon_{\text{test}} + \varepsilon_{\text{release}} = \varepsilon$ (thực nghiệm dùng $\varepsilon_{\text{test}} = \varepsilon_{\text{release}} = \varepsilon/2$).

Nhận xét 4.9 (Đánh đổi thực nghiệm và phạm vi). So với SM-REM (memo chính xác), PR-SM-REM yếu hơn về chống-averaging thực nghiệm nhưng có chặn per-step hữu hạn hợp lệ. Trạng thái chỉ là release trước đó nên nó là predictive reuse của điểm liền trước, không phải memoization bền vững: mẫu rời-rời-quay-lại (nhà→chỗ làm→nhà) không được nhớ (verifier R2-007). θ phải công khai.

4.7 Thuật toán và độ phức tạp

1. **Tiền xử lý** (một lần cho vùng quan tâm): dựng đồ thị đường OSM, chiếu các đỉnh về hệ tọa độ phẳng cục bộ, xây KD-tree trên V .
2. **Mỗi điểm thật** x_t : tính logits $-\frac{\varepsilon}{2}d(x_t, u) + \log w_t(u)$ trên *toàn bộ* tập đỉnh cố định $u \in V$ (REM: $w_t \equiv 1$) — không cắt ngưỡng quanh x_t (Nhận xét 4.3); lấy mẫu bằng Gumbel-max trong miền log; công bố đỉnh được chọn; cập nhật z_t .

Chi phí mỗi điểm là $O(|V|)$ phép tính vector hóa (một 2-norm trên $|V|$ đỉnh + một argmax); với đồ thị Bắc Kinh $|V| = 13\,813$ đỉnh dùng trong thực nghiệm, chi phí này dưới mili-giây trong reference implementation Python. (Đây là chi phí của riêng bước lấy mẫu; con số benchmark tổng gồm cả metrics và attackers nên không dùng làm latency claim on-device — cần đo cách ly trên phần cứng mobile, xem Chương 6.)

Chương 5

Thực nghiệm

5.1 Thiết lập

Dữ liệu. 20 quỹ đạo thật (858 điểm) trích từ GeoLife v1.3 [21], giới hạn trong hộp tọa độ trung tâm Bắc Kinh (39,96; 116,29)–(40,02; 116,36), tách theo khoảng dừng, lấy mẫu lại chu kỳ 20 giây (chế độ mà tương quan thời gian giữa hai điểm liên tiếp còn mạnh — đúng vùng hoạt động của tấn công HMM), mỗi quỹ đạo 20–60 điểm, tối đa 3 quỹ đạo mỗi người dùng.

Lưới đường. Đồ thị OSM dựng từ extract BBBike, cắt về đúng hộp tọa độ GeoLife bằng thứ tự bbox OSMnx 2.x (*left, bottom, right, top*) và giữ thành phần liên thông lớn nhất: **13.813 đỉnh, 41.040 cạnh**, extent lat 39,96–40,02, lon 116,29–116,36 (khớp bbox thí nghiệm; bản trước bị build sai thứ tự bbox nên trải ~98km — verifier R2-005, đã sửa). Tọa độ chiếu về hệ phẳng cục bộ (equirectangular), sai số dưới 1m trong hộp ~9km. Manifest (SHA-256, node/edge count, extent, lệnh build, versions) ở data/beijing_graph.manifest.json.

Cơ chế so sánh. (1) Laplace phẳng thuần (Geo-I gốc [1], bán kính $\text{Gamma}(2, 1/\varepsilon)$, không chặn, không snap); (2) Baseline Thực tập 2 (nhiều chặn tại QoS + làm mượt + snap có kiểm QoS); (3) REM; (4) T-REM ($v_{\max} = 25$ m/s, $s = 100$ m, $\lambda = 0,02$); (5) SM-REM (T-REM + memoization lưới công khai $g = 60$ m); (6) PR-SM-REM (reuse riêng tư, $\theta = 200$ m, ngân sách khớp $\varepsilon_{\text{test}} = \varepsilon_{\text{release}} = \varepsilon/2$). QoS $\delta = 200$ m; $\varepsilon \in \{0,01; 0,02; 0,05\}$ mỗi mét (với PR-SM-REM là ngân sách per-step worst-case); seed cố định 42. Đồ thị lưới đường $|V| = 13\,813$ đỉnh (graph đã sửa bbox, R2-005).

5.2 Độ đo và tấn công

Tiện ích: độ lệch trung bình/lớn nhất giữa điểm thật và điểm công bố (quality loss); tỷ lệ thỏa QoS; recall truy vấn k-NN POI (theo giao thức của [6]); khoảng cách Hausdorff và DTW giữa

hai quỹ đạo. *Tính thực tế*: tỷ lệ điểm công bố nằm trong 25m của lưới đường; tỷ lệ cặp điểm công bố liên tiếp vi phạm tốc độ 30 m/s. *Riêng tư*: sai số của *adversary Bayes* với *emission REM chính xác* — prior đều cố định trên toàn tập đỉnh, $\text{likelihood} \propto \exp(-\frac{\varepsilon}{2}d(x, z))/Z(x)$ với normalizer $Z(x)$ tính đủ trên toàn support, estimator là geometric median (khớp loss khoảng cách). Adversary này *chính xác* cho REM; với T-REM/SM-REM (likelihood phụ thuộc lịch sử/trạng thái) nó là adversary REM-emission cố định áp dụng đồng nhất, *không* tuyên bố là Bayes-optimal riêng cho từng cơ chế. Kèm tấn công theo dõi HMM (forward-backward, cùng emission có $Z(x)$, cột *cov* = tỷ lệ đỉnh proxy của vị trí thật còn trong tập ứng viên sau cắt). Sai số càng *cao* càng riêng tư.

5.3 Kết quả

Bảng 5.1: Kết quả trên 20 quỹ đạo GeoLife (858 điểm), QoS 200m, seed gốc 42 dẫn xuất *độc lập thứ tự chạy* theo (seed, ε , cơ chế) (R2-009). Bayes/HMM err = sai số của adversary REM-emission proxy (m), cao hơn là riêng tư hơn — *cận trên* cho cơ chế non-REM, không phải optimal attacker; cov = HMM candidate coverage. In đậm: cơ chế đề xuất. Provenance (git commit, graph SHA-256) trong outputs/benchmark_results.json.

ε	Cơ chế	Q_loss	QoS	On-road	Spd-viol	Bayes	HMM	cov
0,01	Laplace phẳng	205,7	0,59	0,43	0,08	200,6	125,9	1,00
	Baseline TT2 (surrogate)	93,4	1,00	0,98	0,00	95,2	81,1	1,00
	REM	377,3	0,31	1,00	0,37	375,4	183,3	0,99
	T-REM	321,4	0,36	1,00	0,07	319,8	220,0	0,99
	SM-REM	292,7	0,41	1,00	0,05	289,1	225,2	1,00
	PR-SM-REM	576,1	0,27	1,00	0,52	568,4	324,2	0,89
0,02	Laplace phẳng	99,8	0,90	0,49	0,00	99,1	76,9	1,00
	Baseline TT2 (surrogate)	78,8	1,00	0,98	0,00	80,1	75,1	1,00
	REM	175,4	0,65	1,00	0,04	174,0	121,3	1,00
	T-REM	180,5	0,63	1,00	0,03	179,3	123,5	1,00
	SM-REM	178,8	0,63	1,00	0,02	178,4	144,9	1,00
	PR-SM-REM	283,0	0,52	1,00	0,22	283,0	167,7	0,99
0,05	Laplace phẳng	40,1	1,00	0,58	0,00	44,4	38,4	1,00
	Baseline TT2 (surrogate)	71,2	1,00	0,98	0,00	72,6	72,2	1,00
	REM	69,0	0,98	1,00	0,00	69,2	61,5	1,00
	T-REM	71,5	0,97	1,00	0,00	71,5	63,7	1,00
	SM-REM	71,3	0,98	1,00	0,00	71,3	66,1	1,00
	PR-SM-REM	119,4	0,90	1,00	0,01	117,8	107,0	1,00

Năm quan sát chính từ Bảng 5.1 (số liệu với adversary emission chính xác; đọc thận trọng, tránh overclaim):

1. **Tương quan thời gian là mối đe dọa thực.** Tấn công HMM luôn mạnh hơn tấn công per-point: với Laplace phẳng tại $\varepsilon = 0,01$, sai số adversary giảm từ 200,6m (Bayes) xuống

125,9m (HMM, -37%) chỉ nhờ lọc Bayes theo thời gian — xác nhận thực nghiệm [6] và biện minh việc chọn HMM làm tấn công đánh giá chính.

2. **Laplace phẳng để lộ bề mặt tấn công thực tế.** 42–57% điểm công bố rơi ngoài lưới đường — đúng loại tín hiệu mà RAOPT khai thác. REM/T-REM/ SM-REM/PR-SM-REM đạt 100% trên đường *theo cấu trúc* (đây là structural property, chưa phải bằng chứng attack-resistance — cần chạy RAOPT trực tiếp, xem Chương 6).
3. **T-REM giảm speed-implausibility mà không mất riêng tư.** Tại $\varepsilon = 0,01$, T-REM giảm tỷ lệ vi phạm tốc độ từ 37% (REM) xuống 7%, *đồng thời* giảm quality loss (377,3 → 321,4m) và cho HMM error *cao hơn* (220,0m so REM 183,3m — tức riêng tư hơn). Đây vẫn là soft regularizer theo khoảng cách đường thẳng (không phải hard reachable-set), nên không nên claim “đóng hãm” velocity attack; mức kháng cần test trực tiếp.
4. **Trên đường cong trade-off, lợi thế của cơ chế đường là tính thực tế và guarantee hợp lệ, không phải attacker-error thô.** Tại mức tiện ích tương đương (Laplace @ $\varepsilon=0,01$ disp 205,7m, HMM 125,9m so với T-REM @ $\varepsilon=0,02$ disp 180,5m, HMM 123,5m), sai số HMM gần bằng nhau; cơ chế đường *không* thắng trên trục attacker-error. Lợi thế thật của chúng là: 100% trên đường (không có bề mặt map-matching), vi phạm tốc độ thấp/không, và ε là *đảm bảo hợp lệ* — khác với baseline có ε danh nghĩa đẹp nhưng theo Mệnh đề 4.1, 4.3 không phải guarantee hợp lệ (nên gọi là “surrogate” trong bảng).
5. **Chi phí di chuyển của SM-REM và PR-SM-REM.** SM-REM bám sát T-REM về utility (disp 178,8 vs 180,5m tại $\varepsilon=0,02$; quantize về rep(*cell*) thêm chút lệch) với HMM error cao hơn (144,9 vs 123,5m). PR-SM-REM với *ngân sách khớp* ($\varepsilon_{\text{test}}=\varepsilon_{\text{release}}=\varepsilon/2$) trả giá utility trên quỹ đạo di chuyển: release thô hơn ($\varepsilon/2$) cộng việc reuse giữ điểm cũ khi người dùng đã đi xa làm disp và vi phạm tốc độ tăng, nặng nhất ở ε nhỏ (tại $\varepsilon=0,01$: disp 576m, spd-viol 0,52). Đây là cái giá trung thực của thiết kế chống-averaging + ngân sách công bằng, và lý do cốt lõi của SM-REM/PR-SM-REM — chống averaging tại stay-point — nằm ở Mục 5.5, không ở bảng di chuyển này.

5.4 Tấn công averaging tại stay-point (S4)

Bảng 5.1 đo quỹ đạo *di chuyển*. Nhưng harm thực tế nghiêm trọng nhất (Strava lộ nhà 84–95% [23]; home fingerprinting của broker) đến từ báo cáo *lập tại một điểm tĩnh*: kẻ tấn công thu n điểm công bố của cùng một vị trí nhà rồi hợp nhất để khôi phục nó. Điểm mấu chốt về phương pháp — được đánh giá độc lập nhân mạnh — là *chọn đúng estimator của kẻ tấn công*: với cơ chế nhiễu đối xứng (Laplace phẳng) trung bình mẫu là nhất quán, nhưng với cơ chế lũy thừa trên tập đỉnh có biên thì $\mathbb{E}[Z \mid x] \neq x$ nên trung bình mẫu *chệch*, và attacker đúng là MLE nhất quán $\hat{x} = \arg \max_x [-a \sum_i d(x, z_i) - n \log Z(x)]$ (hội tụ về x). Vì thế phần này báo cáo

trực tiếp thí nghiệm đa-home với attacker MLE ở Mục 5.5; kết quả một-home bằng trung bình mẫu chỉ là minh họa cấu trúc và có thể gây hiểu nhầm (nó làm REM/T-REM trông như kháng averaging trong khi thực ra không).

5.5 Đánh giá averaging đa-home với attacker proxy dạng-REM

Để tránh điểm yếu “một home, một seed” (verifier V-005) và “estimator sai” (V-004), thí nghiệm này theo chuẩn văn liệu [5, 24]: (i) tập **40 stay-point / significant location** rút từ GeoLife (thuật toán Li 2008/Zheng 2009, 200m/20min) trải **21 người dùng** — đây là các điểm dừng lâu, *không* phải nhãn cư trú ground-truth (verifier R2-008); (ii) mỗi điểm $\times$ 8 seed, 100 báo cáo có *nhiều* GPS $\sigma = 10\text{m}$; (iii) *hai estimator* — sample-mean ngây thơ và MLE dạng-REM $\hat{x} = \arg \max_x [-a \sum_i d(x, z_i) - n \log Z(x)]$ (chính xác cho REM, xấp xỉ cho các cơ chế còn lại — xem hạn chế bên dưới); (iv) khoảng tin cậy 95% bootstrap trên các điểm (cluster theo user). Chạy trên graph đã sửa bbox (R2-005), sampler Gumbel-max (R2-006) và ngân sách khớp cho PR-SM-REM ($\varepsilon_{\text{test}} = \varepsilon_{\text{release}} = \varepsilon/2$, R2-003).

Bảng 5.2: Sai số suy luận (m) của attacker MLE dạng-REM theo số báo cáo n (median trên 40 điểm $\times$ 8 seed, $\varepsilon = 0,02$, jitter $\sigma = 10\text{m}$). Thấp = attacker thắng. Cột cuối: xác suất khôi phục vị trí trong 50m ở $n=100$.

Cơ chế	$n=1$	$n=5$	$n=10$	$n=20$	$n=50$	$n=100$	$P[\leq 50\text{m}]$
Laplace phẳng	92,1	40,3	34,4	30,0	28,0	25,2	91%
REM	161,6	83,2	55,9	38,8	33,6	29,8	88%
T-REM	161,6	83,2	55,9	38,8	33,7	29,4	88%
SM-REM	164,5	157,8	149,4	147,1	152,3	150,5	11%
PR-SM-REM	355,9	151,5	116,8	83,7	62,3	47,8	54%

Bảng 5.2 cho câu chuyện dứt khoát và *trung thực*, khác hẳn ấn tượng từ estimator ngây thơ:

1. **Trước attacker MLE, Laplace/REM/T-REM đều KHÔNG kháng averaging.** Sai số sụp theo n về mức tương đương nhau ($n=100$: Laplace 25,2m, REM/T-REM $\approx 30\text{m}$) với xác suất khôi phục trong 50m 88–91%. Sample-mean “phẳng” của REM/T-REM ở thí nghiệm một-home trước chỉ là *artefact* do $\mathbb{E}[Z \mid x] \neq x$ (bias biên), không phải tính riêng tư. (Ta *không* còn khẳng định REM tệ hơn Laplace — với graph đã sửa hai bên xấp xỉ nhau.)
2. **SM-REM là cơ chế duy nhất thật sự phẳng** (150,5m ở mọi n ; chỉ 11% khôi phục trong 50m) — nhưng bằng memo *chính xác*, nên không có đảm bảo trajectory và rò pattern revisit (Nhận xét 4.5).


3. **PR-SM-REM là điểm cân bằng defense-được:** ở cùng ngân sách per-step với REM, chống averaging một phần (47,8m ở $n=100$, tốt hơn REM đáng kể) và có chặn per-step ($\epsilon_{\text{test}} + \epsilon_{\text{release}}$)-Geo-I hữu hạn (Định lý 4.4). Nhiều trên phép thử reuse cho vài resample lọt qua — đó chính là cái giá của một guarantee hợp lệ.

Hạn chế của estimator (verifier R2-004): MLE dạng-REM chỉ đúng family cho REM; cho các cơ chế khác nó là proxy, và không cơ chế nào exact end-to-end dưới GPS jitter (jitter chưa vào likelihood). Một attacker dùng đúng sequential kernel của PR-SM-REM mạnh hơn proxy này (diagnostic độc lập); vì vậy các con số PR/SM là *cận trên lạc quan cho attacker proxy*, cần attacker mechanism-aware đầy đủ để chốt (hướng phát triển). Đối thủ gần nhất là **Eclipse** [26] (IEEE TMC), cùng threat model quan sát-dài-hạn, chống averaging bằng nhiều-phân-phối + k -anonymity *off-road*; SM-REM/PR-SM-REM đạt hiệu ứng tương tự bằng memoization/reuse *on-road* (tiền lệ RAPPOR [27]).

5.6 Hệ thống mô phỏng và kịch bản sử dụng

Để minh họa trade-off một cách trực quan, chúng tôi xây dựng hệ thống mô phỏng web (Hình 5.1) phát lại quỹ đạo GeoLife thật theo thời gian với ba góc nhìn đồng thời: vị trí thật (chỉ người dùng thấy), điểm công bố (thứ duy nhất máy chủ LBS nhận được), và ước lượng của kẻ tấn công HMM trực tuyến kèm sai số từng bước. Trên đó chạy một truy vấn LBS cụ thể — “3 hiệu thuốc gần tôi nhất” — phát tại điểm công bố và được chấm điểm so với đáp án đúng, cho thấy QoS bằng con số theo từng giây.

Bốn kịch bản đòi thực được mô hình hóa: (i) *gọi xe/giao đồ ăn* — ứng dụng cần vị trí thô để điều phối nhưng không được học địa chỉ nhà; (ii) *y tế nhạy cảm* — tìm nhà thuốc gần mà không tiết lộ đang đứng trước phòng khám nào (recall k -NN $\approx 81\%$ tại $\epsilon = 0,02$); (iii) *ứng dụng thể thao/mạng xã hội* — chia sẻ tuyến chạy không lộ điểm xuất phát cho kẻ theo dõi; (iv) *crowdsensing giao thông* — đóng góp dữ liệu tốc độ mà không nộp nguyên hành trình, điểm công bố nằm trên lưới đường nên vẫn map-match được cho mục đích thống kê.



Hình 5.1: Hệ thống mô phỏng: quỹ đạo thật (xanh lá), chuỗi điểm công bố bởi T-REM (đỏ, nét đứt), ước lượng kẻ tấn công HMM (xanh dương), vòng tròn QoS 200m, các POI trả về từ truy vấn k-NN, bảng chỉ số toàn quỹ đạo và đồ thị sai số theo từng bước.

Chương 6

Tổng kết

6.1 Kết quả đạt được

Tính đến bản cập nhật này, luận văn đã: (1) phát biểu lại bài toán theo mô hình triển khai thực tế (local/on-device, granularity theo mục đích, (α, δ) -hữu dụng, bảo vệ endpoint) với bảng yêu cầu ánh xạ vào harm thực tế; (2) chỉ ra và chứng minh hình thức các lỗi phá vỡ đảm bảo Geo-I trong pipeline Thực tập 2; (3) đề xuất REM — cơ chế lũy thừa trên *toàn bộ* tập đỉnh lưới đường cố định với chứng minh ε -Geo-I Euclid cho ideal kernel (bản Euclid của GEM [13]), đầu ra nằm trên đường theo cấu trúc; (4) đề xuất T-REM — trọng số khả đạt chỉ phụ thuộc thông tin công khai, không đòi đảm bảo per-release, *giảm* tín hiệu speed-implausibility (không claim đóng hãm velocity attack); (5) đề xuất SM-REM (đảm bảo cho vị trí tĩnh lặp lại, Định lý 4.3) và **PR-SM-REM** (reuse riêng tư, chặn per-release $(\varepsilon_{\text{test}} + \varepsilon_{\text{release}})$ -Geo-I hữu hạn, Định lý 4.4) — nhằm kích bản averaging mà bản PTPPM stateless [17] bỏ ngỏ; (6) bộ khung đánh giá theo chuẩn văn liệu (Bayes/HMM proxy dạng-REM, averaging đa-home 40×8 với bootstrap CI, quality loss, k-NN POI tổng hợp, tính thực tế) trên dữ liệu GPS thật; (7) hệ thống mô phỏng ba góc nhìn gắn với kịch bản đời thực. Mọi đảm bảo là cho ideal real-arithmetic kernel (Nhận xét 4.7).

6.2 Hạn chế hiện tại

Hiện thực hữu-hạn-độ-chính-xác không phải pure Geo-I. Sampler Gumbel-max và phép thử Laplace dùng RNG 53-bit nên có zero-support phụ thuộc input (Nhận xét 4.7); đảm bảo chỉ đúng cho ideal kernel. Exact discrete sampler = hướng phát triển.

Attacker là proxy, chưa optimal. Bayes/HMM/averaging dùng likelihood dạng-REM, chính xác cho REM nhưng là proxy cho T-REM/SM-REM/PR-SM-REM; GPS jitter chưa vào likelihood. Một attacker sequential đúng của PR mạnh hơn proxy (chẩn đoán độc lập của verifier). Do đó *không* dùng chênh lệch proxy để claim cơ chế này vượt cơ chế kia; cần attacker mechanism-aware + jitter-aware đầy đủ.

Đảm bảo trajectory chưa đầy đủ. PR-SM-REM mới có chặn per-release; một scalar ε_w w-event cần budget manager theo cửa sổ (chưa cài). SM-REM chỉ đảm bảo vị trí tĩnh lặp lại, pattern revisit rõ ràng.

Phạm vi & provenance. Artifact là reference mechanism + simulator Flask phía server, chưa phải hiện thực on-device; cache/định danh lifecycle (R8–R12) ngoài phạm vi. Averaging đa-home dùng stay-point (không phải nhãn cư trú), moving benchmark còn một-seed; clean-clone provenance (build script, seed dẫn xuất, raw rows, dependency lock) đang bổ sung. Chưa chạy RAOPT; chưa so GEM (metric đường đi ngắn nhất)/PIM. Chi tiết đối chiếu ở docs/reviews/.

6.3 Hướng phát triển

1. Chạy tấn công RAOPT (mã nguồn công khai) đối kháng cả bốn cơ chế — chuẩn đánh giá tối thiểu theo SoK PoPETs 2024 [20];
2. Hiện thực GEM với khoảng cách đường đi ngắn nhất và so sánh REM–GEM theo giao thức của [13];
3. Phiên bản δ -location set trên lưới đường: tập ứng viên là các đỉnh khả đạt từ vùng đã công bố, cho đảm bảo kiểu PIM [6] dưới kẻ tấn công Markov;
4. Mở rộng thực nghiệm: Porto Taxi (thành phố thứ hai), 100+ quỹ đạo, nhiều seed với khoảng tin cậy, đường cong Pareto riêng tư–tiện ích dày hơn;
5. Metric co giãn theo ngữ nghĩa trên đồ thị đường (“elastic GG-I”) — khoảng trống chưa có công bố chiếm giữ, kết hợp [10] với [13].

Tài liệu tham khảo

- [1] Miguel E. Andrés, Nicolás E. Bordenabe, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Geo-indistinguishability: Differential privacy for location-based systems. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 901–914, 2013.
- [2] Erik Buchholz, Alsharif Abuadbba, Shuo Wang, Surya Nepal, and Salil S. Kanhere. Re-construction attack on differential private trajectory protection mechanisms. In *Annual Computer Security Applications Conference (ACSAC)*, pages 279–292, 2022.
- [3] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography Conference (TCC)*, pages 265–284, 2006.
- [4] Frank McSherry and Kunal Talwar. Mechanism design via differential privacy. In *IEEE Symposium on Foundations of Computer Science (FOCS)*, pages 94–103, 2007.
- [5] Reza Shokri, George Theodorakopoulos, Jean-Yves Le Boudec, and Jean-Pierre Hubaux. Quantifying location privacy. In *IEEE Symposium on Security and Privacy (S&P)*, pages 247–262, 2011.
- [6] Yonghui Xiao and Li Xiong. Protecting locations with differential privacy under temporal correlations. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 1298–1309, 2015.
- [7] Chi-Yin Chow and Mohamed F. Mokbel. Trajectory privacy in location-based services and data publication. In *ACM SIGSPATIAL International Workshop on Security and Privacy in GIS and LBS (SPRINGL)*, pages 13–20, 2011.
- [8] Trong Nhan Phan and Tran Khanh Dang. A novel trajectory privacy-preserving future time index structure in moving object databases. In *International Conference on Computational Collective Intelligence (ICCCI)*, volume 7653 of *LNCS*, pages 124–134, 2012.
- [9] Trong Nhan Phan, Josef Küng, and Tran Khanh Dang. KUR-algorithm: From position to trajectory privacy protection in location-based applications. In *Database and Expert Systems Applications (DEXA)*, volume 9262 of *LNCS*, pages 82–89, 2015.

- [10] Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Marco Stronati. Constructing elastic distinguishability metrics for location privacy. *Proceedings on Privacy Enhancing Technologies (PoPETs)*, 2015(2):156–170, 2015.
- [11] Nicolás E. Bordenabe, Konstantinos Chatzikokolakis, and Catuscia Palamidessi. Optimal geo-indistinguishable mechanisms for location privacy. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 251–262, 2014.
- [12] Simon Oya, Carmela Troncoso, and Fernando Pérez-González. Back to the drawing board: Revisiting the design of optimal location privacy-preserving mechanisms. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 1959–1972, 2017.
- [13] Shun Takagi, Yang Cao, Yasuhito Asano, and Masatoshi Yoshikawa. Geo-graph-indistinguishability: Protecting location privacy for LBS over road networks. In *IFIP Conference on Data and Applications Security and Privacy (DBSec)*, pages 143–163, 2019. Extended version: arXiv:2010.13449.
- [14] Lei Yu, Ling Liu, and Calton Pu. Dynamic differential location privacy with personalized error bounds. In *Network and Distributed System Security Symposium (NDSS)*, 2017.
- [15] Zhikun Zhang, Huiping Duan, Ming Chen, and Sheng Zhong. On the differential privacy of dynamic location obfuscation with personalized error bounds. *arXiv preprint arXiv:2101.12602*, 2021.
- [16] Mingge Cao, Haopeng Zhu, Minghui Min, Yulu Li, Shiyin Li, Hongliang Zhang, and Zhu Han. Protecting personalized trajectory with differential privacy under temporal correlations. In *IEEE Wireless Communications and Networking Conference (WCNC)*, 2024. arXiv:2401.11225.
- [17] Minghui Min, Kaiqiang Liu, Yang Cao, Yulu Li, Hongliang Zhang, Miao Pan, and Zhu Han. Road network-aware personalized trajectory protection with differential privacy under spatiotemporal correlations. *arXiv preprint arXiv:2511.21020*, 2025.
- [18] Jinmeng Rao, Song Gao, Yuhao Kang, and Qunying Huang. LSTM-TrajGAN: A deep learning approach to trajectory privacy protection. In *International Conference on Geographic Information Science (GIScience)*, 2021.
- [19] Yuanshao Zhu, Yongchao Ye, Shiyao Zhang, Xiangyu Zhao, and James J.Q. Yu. DiffTraj: Generating GPS trajectory with diffusion probabilistic model. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

- [20] Erik Buchholz, Alsharif Abuadbba, Shuo Wang, Surya Nepal, and Salil S. Kanhere. SoK: Can trajectory generation combine privacy and utility? *Proceedings on Privacy Enhancing Technologies (PoPETs)*, 2024(3):75–93, 2024.
- [21] Yu Zheng, Xing Xie, and Wei-Ying Ma. GeoLife: A collaborative social networking service among user, location and trajectory. *IEEE Data Engineering Bulletin*, 33(2):32–39, 2010.
- [22] Konstantinos Chatzikokolakis, Catuscia Palamidessi, and Marco Stronati. A predictive differentially-private mechanism for mobility traces. In *Privacy Enhancing Technologies Symposium (PETS)*, pages 21–41, 2014. arXiv:1311.4008.
- [23] Wajih Ul Hassan, Saad Hussain, and Adam Bates. Analysis of privacy protections in fitness tracking social networks — or — you can run, but can you hide? In *USENIX Security Symposium*, pages 497–512, 2018.
- [24] Karel Dhondt, Victor Le Pochat, Alexios Voulimeneas, Wouter Joosen, and Stijn Volckaert. A run a day won’t keep the hacker away: Inference attacks on endpoint privacy zones in fitness tracking social networks. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 801–814, 2022.
- [25] Georgios Kellaris, Stavros Papadopoulos, Xiaokui Xiao, and Dimitris Papadias. Differentially private event sequences over infinite streams. *Proceedings of the VLDB Endowment (PVLDB)*, 7(12):1155–1166, 2014.
- [26] Ben Niu, Yahong Chen, Boyang Wang, Zhibo Wang, Fenghua Li, and Hui Li. Eclipse: Preserving differential location privacy against long-term observation attacks. *IEEE Transactions on Mobile Computing*, 21(1):125–138, 2022.
- [27] Úlfar Erlingsson, Vasyi Pihur, and Aleksandra Korolova. RAPPOR: Randomized aggregatable privacy-preserving ordinal response. In *ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 1054–1067, 2014.